

**Министерство науки и высшего образования Российской Федерации  
федеральное государственное автономное образовательное учреждение  
высшего образования «Национальный исследовательский университет  
ИТМО»**

*Факультет программной инженерии и компьютерной техники*

**Математическая статистика**  
Расчетно-графическая работа № 1  
Вариант: 3

**Выполнили:**

Вильданов Ильнур Наилевич  
Бондарев Алексей Михайлович  
Группа №Р3212

**Преподаватель:**

Милованович Екатерина Воиславовна

Санкт-Петербург  
2025 г.

|                     |    |
|---------------------|----|
| Задание №1 .....    | 3  |
| 1.1 Условие.....    | 3  |
| 1.2 Выполнение..... | 3  |
| Задание №2.....     | 11 |
| 2.1 Условие.....    | 11 |
| 2.2 Выполнение..... | 11 |
| Задание №3.....     | 15 |
| 3.1 Условие.....    | 15 |
| 3.2 Выполнение..... | 15 |

# Задание №1

## 1.1 Условие

В файле cars93.csv представлены данные об автомобилях, проданных в некотором автосалоне за 93 год. Какие типы автомобилей представлены в датасете? Какой тип наиболее распространен, какой - менее? Рассчитайте выборочное среднее, выборочную дисперсию, выборочную медиану и межквартильный размах мощности для всей совокупности автомобилей и отдельно для американских и не американских авто. Построить график эмпирической функции распределения, гистограмму и box-plot мощности для всей совокупности и отдельно для каждого типа авто.

## 1.2 Выполнение

### Листинг 1: Импорт библиотеки

В данном листинге импортируются библиотеки pandas, numpy и matplotlib, необходимые для работы с данными и построения графиков.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
```

### Листинг 2: Считывание таблицы

```
# Чтение данных из файла cars93.csv
df = pd.read_csv('cars93.csv')
```

### Листинг 3: Анализ типов автомобилей

В этом разделе с помощью метода value\_counts() определяется частота появления каждого типа авто (столбец "Type"). Затем с помощью idxmax() и idxmin() определяется наиболее и наименее распространенный тип.

```
type_counts = df['Type'].value_counts()
print("Частота появления каждого типа автомобилей:")
print(type_counts)

# Определение наиболее и наименее распространенных типов
most_common = type_counts.idxmax()
least_common = type_counts.idxmin()
print("\nНаиболее распространенный тип:", most_common)
print("Наименее распространенный тип:", least_common)
```

### Вывод в консоль:

Частота появления каждого типа автомобилей:

```
Type
Midsize      22
Small        21
Compact      16
Sporty       14
Large        11
Van          9
Name: count, dtype: int64
```

Наиболее распространенный тип: Midsize

Наименее распространенный тип: Van

## Вычисление выборочных характеристик мощности

#### Листинг 4: Функция для вычисления основных статистических характеристик

Определена функция `descriptive_stats()`, которая принимает выборку и возвращает:

- выборочное среднее
- несмещенную дисперсию (с параметром `ddof=1`)
- медиану
- межквартильный размах (IQR)

```
def descriptive_stats(data):  
    mean_val = np.mean(data)  
    variance_val = np.var(data, ddof=1)  
    median_val = np.median(data)  
    q1 = np.percentile(data, 25)  
    q3 = np.percentile(data, 75)  
    iqr_val = q3 - q1  
    return mean_val, variance_val, median_val, iqr_val
```

#### Листинг 5: Расчет статистик мощности

Рассчитываются характеристики для всего набора данных, а также отдельно для американских автомобилей (столбец "Origin" = "USA") и неамериканских.

```
# 'Horsepower'  
hp_all = df['Horsepower']  
  
# Статистики для всей выборки  
stats_all = descriptive_stats(hp_all)  
print("\nСтатистики мощности для всей совокупности:")  
print(f"Среднее: {stats_all[0]:.2f}")  
print(f"Дисперсия (несмещенная): {stats_all[1]:.2f}")  
print(f"Медиана: {stats_all[2]:.2f}")  
print(f"IQR: {stats_all[3]:.2f}")  
  
# Статистики для американских автомобилей  
hp_usa = df[df['Origin'] == 'USA']['Horsepower']  
stats_usa = descriptive_stats(hp_usa)  
print("\nСтатистики мощности для американских автомобилей:")  
print(f"Среднее: {stats_usa[0]:.2f}")  
print(f"Дисперсия (несмещенная): {stats_usa[1]:.2f}")  
print(f"Медиана: {stats_usa[2]:.2f}")  
print(f"IQR: {stats_usa[3]:.2f}")  
  
# Статистики для неамериканских автомобилей  
hp_non_usa = df[df['Origin'] != 'USA']['Horsepower']  
stats_non_usa = descriptive_stats(hp_non_usa)  
print("\nСтатистики мощности для неамериканских автомобилей:")  
print(f"Среднее: {stats_non_usa[0]:.2f}")  
print(f"Дисперсия (несмещенная): {stats_non_usa[1]:.2f}")  
print(f"Медиана: {stats_non_usa[2]:.2f}")  
print(f"IQR: {stats_non_usa[3]:.2f}")
```

Полученные результаты:

Статистики мощности для всей совокупности:

Среднее: 143.83

Дисперсия (несмещенная): 2743.08

Медиана: 140.00

IQR: 67.00

Статистики мощности для американских автомобилей:

Среднее: 147.52

Дисперсия (несмещенная): 2965.32

Медиана: 143.50

IQR: 61.25

Статистики мощности для неамериканских автомобилей:

Среднее: 139.89

Дисперсия (несмещенная): 2537.28

Медиана: 135.00

IQR: 66.00

## Листинг 6: Построение графиков

Код для построения:

- эмпирической функции распределения (ECDF)
- гистограммы
- box-plot мощности

```
def plot_ecdf(data, label, color=None):
    x = np.sort(data)
    n = len(x)
    y = np.arange(1, n + 1) / n
    plt.step(x, y, where='post', label=label, color=color)

# ECDF для всей выборки
plt.figure(figsize=(8, 6))
plot_ecdf(hp_all, label='Все автомобили')
plt.xlabel('Мощность (Horsepower)')
plt.ylabel('ECDF')
plt.title('Эмпирическая функция распределения мощности (Все автомобили)')
plt.legend()
plt.grid(True)
plt.show()

# ECDF по типам автомобилей
plt.figure(figsize=(10, 6))
types = df['Type'].unique()
colors = plt.cm.tab10.colors
for i, t in enumerate(types):
    subset = df[df['Type'] == t]['Horsepower']
    plot_ecdf(subset, label=t, color=colors[i % len(colors)])
plt.xlabel('Мощность (Horsepower)')
plt.ylabel('ECDF')
plt.title('Эмпирическая функция распределения мощности по типам автомобилей')
plt.legend()
plt.grid(True)
plt.show()

# Гистограмма для всей выборки
plt.figure(figsize=(8, 6))
plt.hist(hp_all, bins=10, edgecolor='black')
plt.xlabel('Мощность (Horsepower)')
plt.ylabel('Частота')
plt.title('Гистограмма мощности (Все автомобили)')
plt.grid(True)
```

```
plt.show()

# Гистограммы для каждого типа автомобиля
for t in types:
    plt.figure(figsize=(8, 6))
    subset = df[df['Type'] == t]['Horsepower']
    plt.hist(subset, bins=10, edgecolor='black')
    plt.xlabel('Мощность (Horsepower)')
    plt.ylabel('Частота')
    plt.title(f'Гистограмма мощности для типа: {t}')
    plt.grid(True)
    plt.show()

# Вох-plot для всей выборки
plt.figure(figsize=(8, 6))
plt.boxplot(hp_all, vert=False)
plt.xlabel('Мощность (Horsepower)')
plt.title('Вох-plot мощности (Все автомобили)')
plt.grid(True)
plt.show()

# Вох-plot для каждого типа автомобиля
plt.figure(figsize=(10, 6))
data_to_plot = [df[df['Type'] == t]['Horsepower'] for t in types]
plt.boxplot(data_to_plot, labels=types, vert=False)
plt.xlabel('Мощность (Horsepower)')
plt.title('Вох-plot мощности по типам автомобилей')
plt.grid(True)
plt.show()
```


Функция `plot_ecdf()` строит ступенчатую ECDF, что позволяет оценить накопление вероятности с ростом мощности.

Гистограммы показывают частотное распределение мощности для всей выборки и по категориям.


Вох-plot позволяет увидеть медиану, квартильные значения и наличие выбросов.




*Рис. 1: Эмпирическая функция распределения мощности для всей выборки автомобилей*






**Рис. 2:** Эмпирическая функция распределения мощности, построенная по типам автомобилей





**Рис. 3:** Гистограмма мощности для всей выборки автомобилей











**Рис. 4-9:** Гистограммы мощности для каждого типа автомобиля (по одному графику на каждый тип)



**Рис. 10:** Box-plot мощности для всей выборки автомобилей



*Рис. 11: Box-plot мощности, построенный отдельно для каждого типа автомобиля*

## Задание №2

### 2.1 Условие

Предположите, какому вероятностному закону соответствует распределение показателя, рассмотренного (расчет выборочных характеристик и визуализация) в задании №1. Оцените параметры данного распределения методом максимального правдоподобия или методом моментов (математическое обоснование оценки строго обязательно). Какими статистическими свойствами обладает найденная оценка (обосновать)? Найти теоретические смещение, дисперсию, MSE (или хотя бы написать теоретические формулы, по которым данные показатели вычисляются, если в итоге получается «очень сложный» интеграл/ряд), информацию Фишера (если определена для вашей модели).

### 2.2 Выполнение

Мы предполагаем, что показатель мощности  $X$  для автомобилей имеет нормальное распределение, то есть:

$$X \sim N(\mu, \sigma^2)$$

Наша задача оценить параметры  $\mu$  (среднее) и  $\sigma^2$  (дисперсию) с использованием метода максимального правдоподобия (MLE) (или метода моментов, но мы рассмотрим именно MLE). Также нужно обсудить свойства полученных оценок: смещение, дисперсию, среднеквадратичную ошибку (MSE) и вычислить информацию Фишера для модели.

#### 1. Функция плотности и функция правдоподобия

Функция плотности нормального распределения:

$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

Это стандартная формула, которая показывает, какова вероятность получить конкретное значение  $x$  при данных параметрах  $\mu$  и  $\sigma^2$ .

Теперь, если у нас есть выборка  $x_1, x_2, \dots, x_n$  (например, мощности всех автомобилей), то функция правдоподобия, которая показывает совокупную вероятность наблюдать эту выборку, выглядит так:

$$L(\mu, \sigma^2) = \prod_{i=1}^n f(x_i; \mu, \sigma^2)$$

Так как произведение многих экспонент трудно анализировать, удобнее взять логарифм этой функции. Получаем логарифмическую функцию правдоподобия:

$$\ell(\mu, \sigma^2) = \ln L(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

#### 2. Нахождение оценок методом максимального правдоподобия

Чтобы найти оптимальные оценки  $\hat{\mu}$  и  $\hat{\sigma}^2$ , мы максимизируем логарифмическую функцию правдоподобия по параметрам  $\mu$  и  $\sigma^2$ . Мы ищем такие  $\mu$  и  $\sigma^2$ , при которых  $\ell(\mu, \sigma^2)$  максимально.

## 2.1 Оценка $\mu$

Для  $\mu$  берем производную логарифмической функции правдоподобия по  $\mu$ :

$$\frac{\partial \ell}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu)$$

Приравнивая эту производную к нулю, получаем условие:

$$\sum_{i=1}^n (x_i - \mu) = 0$$

Это условие сразу дает нам:

$$\hat{\mu} = \bar{x}$$

то есть оценка среднего равна выборочному среднему, что интуитивно понятно: если сложить все наблюдения и разделить их на число, то получится центр распределения.

## 2.2 Оценка $\sigma^2$

Теперь найдем оценку дисперсии. Берем производную логарифмической функции правдоподобия по  $\sigma^2$ :

$$\frac{\partial \ell}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2$$

При подстановке  $\mu = \bar{x}$  (так как мы уже нашли  $\hat{\mu}$ ) и приравнивании к нулю получаем:

$$-\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \bar{x})^2 = 0$$

Домножая на  $2\sigma^4$  и решая относительно  $\sigma^2$ , получаем:

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Важно отметить: эта оценка для  $\sigma^2$  является максимального правдоподобия и, как правило, оказывается смещенной (то есть математическое ожидание этой оценки не равно истинной дисперсии, а равно  $\frac{n-1}{n} \sigma^2$ ). Для получения несмещенной оценки делили бы сумму квадратов отклонений на  $n - 1$ , но в методе MLE принято делить на  $n$ .

## 3. Объяснение свойств среднего и дисперсии

### 3.1 Оценка среднего

Метод максимального правдоподобия для нормального распределения приводит к тому, что оценка среднего равна выборочному среднему:

$$\hat{\mu} = \bar{x}$$

Это обоснование основано на том, что математическое ожидание выборочного среднего равно истинному среднему (т.е.,  $E[\bar{x}] = \mu$ ).

Таким образом, эта оценка является **несмещенной** и **эффективной**, поскольку достигает минимальной возможной дисперсии среди всех несмещенных оценок, а ее точность улучшается с ростом объема выборки (дисперсия  $\sigma^2/n$ ).

### 3.2 Оценка дисперсии

В случае нормального распределения метод максимального правдоподобия дает оценку дисперсии в виде:

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Эта оценка оказывается **смещенной**. Математически можно показать, что:

$$E[\hat{\sigma}^2] = \frac{n-1}{n} \sigma^2$$

то есть в среднем полученное значение немного меньше истинного дисперсионного значения. Такое смещение возникает потому, что при вычислении выборочного среднего мы используем все наблюдения, что уменьшает число степеней свободы на единицу. Для получения несмещенной оценки дисперсии обычно используют деление на  $n-1$  (т.е.,  $S^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2$ ), но в методе ММП принято делить на  $n$ , так как это соответствует максимизации функции правдоподобия.

Несмотря на смещение, оценка  $\hat{\sigma}^2$  является **состоятельной**, то есть при  $n \rightarrow \infty$  она сходится к истинному  $\sigma^2$ .

Дисперсия оценки  $\hat{\sigma}^2$  рассчитывается сложнее, но ее можно записать через моменты  $\chi^2$ -распределения. Среднеквадратичная ошибка (**MSE**) равна сумме дисперсии и квадрата смещения.

## 4. Информация Фишера

### 4.1 Общая идея

Информация Фишера для параметра  $\theta$  определяется как

$$I(\theta) = -\mathbb{E} \left[ \frac{\partial^2}{\partial \theta^2} \ln L(\theta; x) \right]$$

где  $L(\theta; x)$  - функция правдоподобия, а  $\ln L(\theta; x)$  - логарифмическая функция правдоподобия. Фактически, мы берем вторую производную логарифма правдоподобия по оцениваемому параметру, берем ее математическое ожидание (среднее) и ставим перед ним знак “-”.

### 4.2 Логарифмическая функция правдоподобия

Для нормального распределения  $N(\mu, \sigma^2)$  с неизвестными  $\mu$  и  $\sigma^2$  и выборкой  $x_1, x_2, \dots, x_n$  функция правдоподобия:

$$L(\mu, \sigma^2) = \prod_{i=1}^n f(x_i; \mu, \sigma^2)$$

$$L(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left( -\frac{(x_i - \mu)^2}{2\sigma^2} \right)$$

Тогда логарифм правдоподобия равен

$$\ell(\mu, \sigma^2) = \ln L(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

#### 4.3 Информация Фишера для $\mu$

Берем вторую производную  $\ell(\mu, \sigma^2)$  по  $\mu$

При этом удобно сначала найти

$$\frac{\partial \ell}{\partial \mu} \text{ и } \frac{\partial^2 \ell}{\partial \mu^2}$$

Оказывается, что

$$\frac{\partial^2 \ell}{\partial \mu^2} = -\frac{n}{\sigma^2}$$

(Знак “-“ возникает из-за того, что в логарифмической функции правдоподобия есть  $-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$ ).

Чтобы найти информацию Фишера, нужно взять математическое ожидание от  $\frac{\partial^2 \ell}{\partial \mu^2}$ . Но  $\sigma^2$  считается истинным (константой) для вывода информации Фишера по  $\mu$ . В итоге:

$$I(\mu) = -\mathbb{E} \left[ \frac{\partial^2 \ell}{\partial \mu^2} \right] = - \left[ -\frac{n}{\sigma^2} \right] = \frac{n}{\sigma^2}$$

Чем больше  $n$ , тем точнее мы можем оценить среднее (ошибка убывает пропорционально  $1/n$ ), а чем больше  $\sigma^2$ , тем сложнее отличать значения вокруг  $\mu$ .

Как итог, точность оценивания  $\mu$  растет линейно с  $n$  и обратно пропорционально  $\sigma^2$ .

#### 4.4 Информация Фишера для $\sigma^2$

Аналогично берем вторую производную  $\ell(\mu, \sigma^2)$  по  $\sigma^2$

При этом  $\mu$  считается известным (или зафиксированным на истинном значении) для вывода информации Фишера именно по  $\sigma^2$ .

После вычислений оказывается, что:

$$\frac{\partial^2 \ell}{\partial (\sigma^2)^2} = -\frac{n}{2(\sigma^2)^2}$$

Тогда:

$$I(\sigma^2) = -\mathbb{E} \left[ \frac{\partial^2 \ell}{\partial (\sigma^2)^2} \right] = - \left[ -\frac{n}{2(\sigma^2)^2} \right] = \frac{n}{2(\sigma^2)^2} = \frac{n}{2\sigma^4}$$

Чем больше объем выборки  $n$ , тем лучше оценивается дисперсия, но точность зависит и от квадрата  $\sigma$ : при очень большой  $\sigma^2$  оценка дисперсии требует большего числа наблюдений.

## Задание №3

### 3.1 Условие

Пусть  $P_\theta$  – выбранное в предыдущем задании распределение, параметризуемое вектором  $\theta$  (пример – равномерное распределение на  $[-2\theta; 4\theta]$ ,  $\hat{\theta} = \bar{X}$ ),  $\hat{\theta}$  – оценка параметра  $\theta$ , полученная в предыдущем упражнении. Проведите численный эксперимент по следующей схеме:

- Зафиксируйте конкретное значение  $\theta = \theta_0$
- Заведите массив  $\{n_1, \dots, n_k\}$  объемов выборки
- Сгенерируйте из распределения  $P_{\theta_0}$  достаточно большое количество  $M$  выборок объема  $n$ , где  $n$  принимает значения из массива  $\{n_1, \dots, n_m\}$ . Для каждой сгенерированной выборки вычислите оценку  $\hat{\theta}$
- Эмпирически рассмотреть поведение оценки  $\hat{\theta}$  в зависимости от объема выборки (можно для каждого объема выборки  $n_i$  вывести описательные статистики для оценок, изобразить гистогramму, box-plot, violin-plot).

### 3.2 Выполнение

#### Листинг 1: Импортирование библиотек

```
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import pandas as pd
```

#### Листинг 2: Настройка эксперимента

```
mu_true = 100.0 # "истинное" среднее
sigma_true = 15.0 # "истинное" стандартное отклонение (дисперсия = 225)
n_values = [10, 30, 50, 100, 300, 500] # различные объемы выборок
M = 1000 # количество выборок для каждого n

# Для воспроизводимости эксперимента
np.random.seed(42)
```

Задаем истинные параметры нормального распределения: среднее = 100 и  $\sigma = 15$ .

Массив `n_values` перечисляет, какие объемы выборки мы будем тестировать.

`M = 1000` означает, что для каждого  $n$  мы генерируем 1000 независимых выборок, чтобы иметь статистически наглядный результат.

`np.random.seed(42)` фиксирует зерно генератора случайных чисел для воспроизводимости.

#### Листинг 3: Функция для вычисления оценок методом ММП

```
def mle_estimates(sample):
    """
    Возвращает MLE-оценки для (mu, sigma^2) в случае нормального
    распределения:
    mu_hat = mean(sample)
    sigma2_hat = sum((x_i - mu_hat)^2)/n
    """
    n = len(sample)
    mu_hat = np.mean(sample)
    sigma2_hat = np.sum((sample - mu_hat)**2) / n
    return mu_hat, sigma2_hat
```

По формуле метода максимального правдоподобия для нормального распределения:

Оценка среднего = обычное среднее выборки.

Оценка дисперсии = сумма квадратов отклонений, деленная на  $n$  (это смещенная оценка, но она является ММП-оценкой).

#### Листинг 4: Генерация выборок и вычисление оценок

```
results_mu = {}
results_sigma2 = {}

for n in n_values:
    mu_hats = []
    sigma2_hats = []
    for _ in range(M):
        sample = np.random.normal(loc=mu_true, scale=sigma_true, size=n)
        mu_hat, sigma2_hat = mle_estimates(sample)
        mu_hats.append(mu_hat)
        sigma2_hats.append(sigma2_hat)
    results_mu[n] = mu_hats
    results_sigma2[n] = sigma2_hats
```

В цикле по  $n\_values$  мы каждый раз создаем пустые списки  $mu\_hats$  и  $sigma2\_hats$ . Затем 1000 раз генерируем выборку объема  $n$  из нормального распределения, считаем оценки  $\hat{\mu}$  и  $\hat{\sigma}^2$ . Результаты (списки из 1000 оценок) сохраняем в словари  $results\_mu$  и  $results\_sigma2$ , где ключ =  $n$ .

#### Листинг 5: Анализ результатов и построение графиков

```
print("РЕЗУЛЬТАТЫ ЭКСПЕРИМЕНТА")
print("n      mean(mu_hat)  bias(mu_hat)      mean(sigma2_hat)
bias(sigma2_hat)")
for n in n_values:
    mu_arr = np.array(results_mu[n])
    sigma2_arr = np.array(results_sigma2[n])
    mean_mu = np.mean(mu_arr)
    mean_sigma2 = np.mean(sigma2_arr)
    bias_mu = mean_mu - mu_true
    bias_sigma2 = mean_sigma2 - sigma_true**2
    print(f"{n:3d}  {mean_mu:12.2f}  {bias_mu:12.2f}  {mean_sigma2:16.2f}
{bias_sigma2:12.2f}")

all_mu = []
all_sigma2 = []
all_n = []
for n in n_values:
    all_mu.extend(results_mu[n])
    all_sigma2.extend(results_sigma2[n])
    all_n.extend([n]*M)

df_results = pd.DataFrame({
    "n": all_n,
    "mu_hat": all_mu,
    "sigma2_hat": all_sigma2
})

# Boxplot для mu_hat
plt.figure(figsize=(10,5))
sns.boxplot(x="n", y="mu_hat", data=df_results, showfliers=False)
plt.axhline(mu_true, color='red', linestyle='--', label="Истинное  $\mu$ ")
plt.title("Boxplot оценок mu_hat по n")
plt.legend()
plt.grid(True)
plt.show()
```



```

# Boxplot для sigma2_hat
plt.figure(figsize=(10,5))
sns.boxplot(x="n", y="sigma2_hat", data=df_results, showfliers=False)
plt.axhline(sigma_true**2, color='red', linestyle='--', label="Истинное  $\sigma^2$ ")
plt.title("Boxplot оценок sigma^2_hat по n")
plt.legend()
plt.grid(True)
plt.show()

# гистограмма для mu_hat при n=50
plt.figure(figsize=(10,5))
subset_mu = df_results[df_results["n"] == 50]["mu_hat"]
plt.hist(subset_mu, bins=20, edgecolor='black')
plt.axvline(mu_true, color='red', linestyle='--', label="Истинное  $\mu$ ")
plt.title("Гистограмма mu_hat (n=50)")
plt.legend()
plt.grid(True)
plt.show()

# Violin-plot для mu_hat
plt.figure(figsize=(10,5))
sns.violinplot(x="n", y="mu_hat", data=df_results)
plt.axhline(mu_true, color='red', linestyle='--', label="Истинное  $\mu$ ")
plt.title("Violin-plot mu_hat по n")
plt.legend()
plt.grid(True)
plt.show()

```

1. Для каждого  $n$  в консоль выводится среднее значение оценок  $\hat{\mu}$  и  $\hat{\sigma}^2$ , а также их смещение (разница с истинным значением).
2. Boxplot показывает, как распределяются оценки при разных  $n$ .
3. На гистограмме (пример для  $n = 50$ ) мы видим, что оценки  $\hat{\mu}$  распределены вокруг 100, а красная пунктирная линия - истинное среднее.
4. В violin-plot скрипки показывают форму распределения оценок при каждом  $n$ . При больших  $n$  скрипка становится более узкой, и медиана все ближе к истинному среднему.

Вывод в консоль:

| РЕЗУЛЬТАТЫ ЭКСПЕРИМЕНТА |              |              |                  |                  |
|-------------------------|--------------|--------------|------------------|------------------|
| n                       | mean(mu_hat) | bias(mu_hat) | mean(sigma2_hat) | bias(sigma2_hat) |
| 10                      | 99.97        | -0.03        | 204.38           | -20.62           |
| 30                      | 99.97        | -0.03        | 217.12           | -7.88            |
| 50                      | 100.07       | 0.07         | 221.09           | -3.91            |
| 100                     | 100.00       | -0.00        | 222.04           | -2.96            |
| 300                     | 99.97        | -0.03        | 224.69           | -0.31            |
| 500                     | 99.97        | -0.03        | 224.58           | -0.42            |




Рис. 12: Violin-plot  $\hat{\mu}$

Здесь видно, что при  $n = 10$  разброс оценок большой, а при  $n = 500$  скрипка сужается вокруг 100. Медиана и толщина распределения подтверждают, что оценки сходятся к истинному значению.




Рис. 13: гистограмма  $\hat{\mu}$  ( $n = 50$ )

Пик гистограммы около 100, а красная линия (истинное среднее) проходит почти по центру. Разброс виден от  $\sim 92$  до  $\sim 108$ . С ростом  $n$  гистограмма становится уже.




Рис. 14: Boxplot оценок  $\sigma^2$

На графике видно, что при  $n = 10$  оценки дисперсии могут быть заметно ниже или выше 225 (истинного значения). При  $n = 500$  ящик и усы сужаются, медиана почти совпадает с 225.




Рис. 15: Boxplot оценок  $\mu$

При  $n = 10$  ящик большой, а медиана может отличаться от 100. При  $n = 500$  медиана близка к 100, и коробка узкая.

Вывод:

- При больших  $n$  средние значения оценок  $\hat{\mu}$  и  $\hat{\sigma}^2$  приближаются к истинным параметрам (100 и 225).
- Смещение оценки дисперсии заметно при малом  $n$ , но уменьшается при больших  $n$ .

- Boxplot и violin-plot наглядно показывают, как с ростом объема выборки разброс оценок сокращается.
- Гистограмма (на примере  $n = 50$ ) демонстрирует, что оценки среднего распределяются примерно гауссово вокруг истинного значения.

Таким образом, численный эксперимент подтверждает, что метод максимального правдоподобия дает хорошие (состоятельные) оценки: они сходятся к истинным параметрам по мере увеличения объема выборки.